

SARRA BEN THAYER

Ingénieure des Données et Systèmes Décisionnels

sarrabenthayer@gmail.com | 92 709 949 | Tunis, Tunisie | LinkedIn

PROFILE

Diplômée en Data Engineering avec une expérience pratique en conception de pipelines de données, systèmes de bases de données et modélisation de données, acquise à travers des projets académiques et des stages. Rigoureuse et minutieuse, avec une réelle motivation à apprendre et à relever de nouveaux défis. Passionnée par la transformation de données brutes en insights clairs et exploitables ayant un impact concret, et à la recherche d'une opportunité pour approfondir son expertise technique au sein d'une équipe data-driven.

EDUCATION

Ingenieure de Données et Systèmes Décisionnels : École Nationale d'Électronique et des Télécommunications de Sfax 2023 – 2026

Cycle Préparatoire Physique-Technologie : Institut Préparatoire aux Études d'Ingénieur de Nabeul 2021 – 2023

EXPÉRIENCE PROFESSIONNELLE

AI-Powered Data Modeler — Projet de Fin d'Etude —TALAN 2/2026 - 6/2026

- Agent Parser : Extrait les éléments structurels du schéma (tables, colonnes, clés primaires/étrangères, types de données) directement à partir de documents bruts hétérogènes grâce à un parsing basé sur des LLM, puis stocke le schéma normalisé dans PostgreSQL
- Agent Extractor : Transforme le schéma extrait en un graphe de connaissances sémantique qui capture les relations entre entités, les dépendances et la sémantique métier au-delà de la structure brute ; chaque état du graphe est versionné dans Neo4j, permettant une traçabilité complète et un retour en arrière possible.
- Agent Validator : Exécute des vérifications structurelles automatisées (intégrité référentielle, cohérence des clés) et sémantiques (cohérence des relations, cohérence des noms/types) sur le graphe de connaissances, produisant un rapport de validation détaillé ainsi qu'un graphe corrigé automatiquement
- Agent Modeler : Convertit le graphe validé en schémas de modélisation formels (Star, Snowflake, Galaxy), les déploie automatiquement, et expose une interface d'interrogation en langage naturel permettant aux utilisateurs non techniques de requêter directement le modèle obtenu.
- Pipeline de mise à jour incrémentale : Utilise le hachage de contenu pour détecter les écarts de schéma entre les versions successives des fichiers, puis génère automatiquement les scripts de migration correspondants

Banking Chatbot — Stagiere d'Ete — Société Tunisienne de Banque (STB) 6/2025 - 7/2025

- Développement d'un chatbot basé sur le NLP pour traiter les requêtes clients liées aux comptes et fournir des insights financiers, via l'entraînement de modèles personnalisés de reconnaissance d'intention pour la compréhension du langage naturel.
- Interface React interactive : Développement d'une interface permettant des interactions conversationnelles en temps réel.

PROJETS ACADÉMIQUES

Plateforme d'Analyse des Réseaux Sociaux en Temps Réel

- Conception d'un pipeline de streaming ingérant des publications de réseaux sociaux en temps réel via Kafka.
- Traitement des flux avec Spark pour l'analyse de sentiment, le suivi des hashtags et des statistiques par fenêtres temporelles.
- Utilisation de Redis pour mettre en cache les statistiques fréquentes/temps réel, réduisant la charge directe sur PostgreSQL.
- Stockage des résultats d'analyse (scores de sentiment, comptages de hashtags, statistiques de tendances) dans PostgreSQL.
- Développement d'APIs backend avec Flask, connectant la logique de traitement à un tableau de bord interactif.
- Conteneurisation des services avec Docker pour simplifier l'orchestration et le déploiement.

Streaming des Ventes en Temps Réel

- Architecture de streaming de bout en bout avec Apache Kafka pour ingérer des données de ventes simulées en temps réel, et Spark Structured Streaming pour un traitement en micro-batch avec watermarking pour gérer les événements en retard.
- Implémentation d'un Lakehouse moderne avec Delta Lake suivant l'architecture médaillon (Bronze → Silver), garantissant des transactions ACID, des capacités de time-travel et des agrégations incrémentales pour l'analyse métier.
- Développement d'un pipeline complet Python/PySpark : producteur Kafka simulant des transactions de vente réalistes, consommateurs Spark pour les transformations en temps réel, et tableau de bord Power BI connecté aux tables Silver pour la visualisation des KPI.

Projet de Pipeline MLOps

- Construction d'un système MLOps de bout en bout pour automatiser la gestion des données, l'entraînement des modèles et le déploiement.
- Utilisation de DVC, MLflow et DagsHub pour le suivi des expérimentations, le versioning et la collaboration.
- Déploiement du modèle entraîné via FastAPI (API REST) et Streamlit pour l'interaction utilisateur.
- Implémentation du monitoring des modèles avec Arize AI et déploiement via Docker.

Compétences Techniques

- **Intelligence Artificielle :** ML, DL, LLMs, NLP, MLOps, IA Générative, LSTM, Graphes de Connaissances
- **Langages de Programmation :** Python, C, Java, Scala, R
- **Technologies Big Data** : Apache Spark, PySpark, Spark Streaming, Kafka, DataBricks, Hive, HDFS, Hadoop
- **Bases de Données :** SQL, NoSQL, MySQL, MongoDB, Neo4j, PostgreSQL, DBeaver, Bases de Données Vectorielles
- **Frameworks et Outils :** REST API, PyTorch, TensorFlow, Scikit-learn, OpenCV, Pandas, NumPy, Matplotlib, Seaborn, Streamlit, LangGraph, LangChain, Power BI
- **Conteneurisation :** Docker, Kubernetes

Langues

Arabe : Langue maternelle **Anglais :** Courant **Français :** Courant

Activités Extrascolaires

- Vice-Présidente, IEEE Computer Society 2023 – 2024
- Membre AIESEC – Volontaire international sortant (Outgoing Global Volunteer) 2021 – 2023